# Метрики качества

## Задача классификации

Выборка:  $X^l = \{x_1, ..., x_l\}$ 

Ответы:  $y_i \in \{0,1\}, i = 1, ..., l$ 

Алгоритм:  $a: X \to Y$ 

Задача: измерить качество алгоритма a на выборке  $X^l$ .

#### Accuracy

Доля правильных ответов на выборке:

$$\frac{1}{l} \sum_{i=1}^{l} [a(x_i) = y_i]$$

#### Пример

- 950 объектов класса 0;
- 50 объектов класса 1;
- a(x) = 0 для всех x.

Доля правильных ответов a(x) : 95%

Базовая доля правильных ответов:

BaseRate = 
$$\underset{y_0 \in \{0,1\}}{\arg \max} \frac{1}{l} \sum_{i=1}^{l} [a(x_i) = y_i]$$

## Матрица ошибок

	y = 1   y = 0	
a(x) = 1	True Positive (TP)	False Positive (FP)
a(x) = 0	False Negative (FN)	True Negative (TN)

$$accuracy = \frac{TP + TN}{TP + FP + FN + TN}$$

http://scikit-learn.org/stable/modules/generated/sklearn.metrics.confusion\_matrix.html

#### Пример

Задача медицинской диагностики (y=1 — больные, y=0 —

здоровые)

	y = 1	y = 0
a(x) = 1	20	50
a(x) = 0	5	1000

Доля правильных ответов: 94.9%

	y = 1	y = 0
a(x)=1	0	0
a(x) = 0	25	1050

Доля правильных ответов: 97.6%

#### Точность и полнота


Точность (precision) — насколько можно доверять классификатору

$$precision = \frac{TP}{TP + FP}$$

	y = 1	y = 0	
a(x) = 1	20	50	
a(x) = 0	5	1000	

Точность классификатора: 28.6%

Точность константного классификатора: 0%



#### Точность и полнота

Полнота (recall) — как много объектов класса 1 находит


классификатор

$$recall = \frac{TP}{TP + FN}$$

	y = 1	y = 0
a(x)=1	20	50
a(x) = 0	5	1000

Точность классификатора: 80%

Точность константного классификатора: 0%



#### Пример

Пример 1: определение мошеннических действий на банковских счетах.

Важнее полнота: лучше проверить лишний раз, чем пропустить вредоносные действия


**Пример** 2: поиск вражеских самолетов для автоматического уничтожения ракетой

Важнее точность: нельзя допустить стрельбы по своему самолету.

#### Усреднение точности и полноты

$$A = \frac{1}{2}(precision + recall)$$

Если precision = 0.05, recall = 1, то A = 0.525. Если precision = 0.525, recall = 0.525, то A = 0.525



#### Усреднение точности и полноты


 $M = \min(precision, recall)$ 

Если precision = 0.05, recall = 1, то M = 0.05.

Если precision = 0.525, recall = 0.525, то M = 0.525.

Если precision = 0.2, recall = 1, то M = 0.2.

Если precision = 0.2, recall = 0.3, то M = 0.2.



#### Усреднение точности и полноты


$$F = \frac{2 * percision * recall}{percision + recall}$$

Если precision = 0.05, recall = 1, то F = 0.1.

Если precision = 0.525, recall = 0.525, то F = 0.525.

Если precision = 0.2, recall = 1, то F = 0.33.

Если precision = 0.2, recall = 0.3, то F = 0.24.



## Правило классификации

$$a(x) = [b(x) > t]$$

b(x) - оценка принадлежности классу 1

t — порог классификации

## Линейный классификатор

$$a(x) = [\langle w, x \rangle > 0]$$

## Метод *k* ближайших соседей

$$a(x) = \left[\sum_{i=1}^{k} [y^{(i)} = 1] > k/2\right]$$


#### PR-кривая

- 1. Сортировка объектов по возрастанию оценки b(x)
- 2. Перебор порогов классификации, начиная с максимального:

$$t_l = b(x_{(l)}), \dots t_1 = b(x_{(1)})$$

- 3. Подсчёт для каждого порога точности и полноты
- 4. Отображение соответствующей точки в осях «полнота-точность»

## Пример



b(x)	0.14	0.23	0.39	0.52	0.73	0.90
у	0	1	0	0	1	1

$$precision = \frac{TP}{TP + FP}$$
 
$$recall = \frac{TP}{TP + FN}$$

	y = 1	y = 0		
a(x) = 1	True Positive (TP)	False Positive (FP)		
a(x) = 0	False Negative (FN)	True Negative (TN) 17		

#### PR-кривая

- 1) Если выборка идеально разделима, то кривая пройдет через точку (1,1);
- 2) Чем больше площадь под кривой, тем лучше.

AUC-PRC (Area Under Precision-Recall curve) — мера качества для b(x).

#### ROC-кривая

ROC — «reciever operating characteristic»

1. По оси X: False Positive Rate, доля ошибочных положительных классификаций:

$$FPR = \frac{FP}{FP + TN}$$


FPR называется специфичностью алгоритма.

2. По оси *Y*: True Positive Rate, доля правильных положительных классификаций:

$$TPR = \frac{TP}{TP + FN}$$

TPR называется чувствительностью алгоритма.

# Пример



<i>b</i> ( <i>x</i> )	0.14	0.23	0.39	0.52	0.73	0.90
у	0	1	0	0	1	1

#### Свойства

- 1. Левая точка: всегда (0,0) (все объекты относим к классу 0);
- 2. Правая точка: всегда (1,1) (все объекты относим к классу 1);
- 3. Если выборка идеально разделима, то кривая пройдет через точку (1,0);
- 4. Площадь меняется от 1/2 до 1;
- 5. Чем больше площадь под кривой, тем лучше.

AUC-ROC (Area Under ROC-curve) — мера качества для b(x).

#### ROC-кривая

$$TPR = \frac{TP}{TP + FN} FPR = \frac{FP}{FP + TN}$$

1. Метрики качества нормируются на размеры классов, ROCкривая не изменится при перемене соотношения классов.

2. Имеет проблемы при сильном дисбалансе классов.

#### PR-кривая

$$precision = \frac{TP}{TP + FP}$$
  $recall = \frac{TP}{TP + FN}$ 

- 1. Точность нормируется на число положительных прогнозов, изменится при перемене соотношения классов.
- 2. Максимально возможная площадь под PR-кривой зависит от соотношения классов.
- 3. Хорошо подходит для измерения качества при сильном дисбалансе классов

## Пример

#### Алгоритм 1:

$$TPR = \frac{TP}{TP + FN} = \frac{90}{90 + 10} = 0.9$$

$$FPR = \frac{FP}{FP + TN} = \frac{10}{10 + 999890} = 0.00001$$

#### Алгоритм 1:

$$precision = \frac{TP}{TP + FP} = 90/(90 + 10) = 0.9$$

$$recall = \frac{TP}{TP + FN} = 90/(90 + 10) = 0.9$$

#### Алгоритм 2:

$$TPR = \frac{TP}{TP + FN} = \frac{90}{90 + 10} = 0.9$$

$$FPR = \frac{FP}{FP + TN} = \frac{1910}{1910 + 997990} = 0.00191$$

#### Алгоритм 2:

$$precision = \frac{TP}{TP+FP} = \frac{90}{90+1910} = 0.045$$

$$recall = \frac{TP}{TP + FN} = \frac{90}{90 + 10} = 0.9$$

## Взвешенная точность (weighted accuracy)

We will first consider evaluation measures for classification in the general case of two or more classes (i.e.,  $M \ge 2$ ) [1]. The most common measure is the probability that an instance of the test set is classified correctly. This is usually referred to as (weighted) accuracy WA, or weighted average recall or recognition rate.

WA = 
$$\frac{\text{\# correctly classified test instances}}{\text{\# test instances}}$$
$$= \frac{\sum_{i=1}^{M} \left| \left\{ \underline{x} \in \mathcal{T}_{i} \mid \hat{y} = i \right\} \right|}{|\mathcal{T}|}.$$
 (7.86)

If this rate is given per class i, one speaks of the class-specific recall  $RE_i$ :

$$RE_{i} = \frac{\left|\left\{\underline{x} \in \mathcal{T}_{i} \mid \hat{y} = i\right\}\right|}{T_{i}}.$$
(7.87)

With  $p_i = T_i/|T|$  as the prior probability of class i in the test set further holds:

$$WA = \sum_{i=1}^{M} p_i RE_i.$$
 (7.88)

# Невзвешенная точность (unweighted accuracy)

If balance of instances among classes is (highly) unbalanced, one can prefer to exchange the priors  $p_i$  for all classes by the constant weight  $\frac{1}{M}$ . This is known as unweighted accuracy UA or unweighted average recall:


$$UA = \frac{\sum_{i=1}^{M} RE_i}{M}.$$
(7.90)

## Weighted vs Unweighted accuracy

Weighted accuracy is computed by taking the average, over all the classes, of the fraction of correct predictions in this class (i.e. the number of correctly predicted instances in that class, divided by the total number of instances in that class). Unweighted accuracy is the fraction of instances predicted correctly (i.e. total correct predictions, divided by total instances).

The distinction between these two measures is useful especially if there exist classes that are under-represented by the samples. Unweighted accuracy gives the same weight to each class, regardless of how many samples of that class the dataset contains. Weighted accuracy weighs each class according to the number of samples that belong to that class in the dataset.

## Weighted vs Unweighted accuracy



```
from sklearn import svm, datasets
from sklearn.model selection import train test split
import numpy as np
iris = datasets.load iris()
X = iris.data
y = iris.target
# Add noisy features
random state = np.random.RandomState(0)
n samples, n features = X.shape
X = np.c [X, random state.randn(n samples, 200 * n features)]
# Limit to the two first classes, and split into training and test
X train, X test, y train, y test = \frac{\text{train test split}}{\text{(X[y < 2], y[y < 2],}}
                                                      test size=.5,
                                                      random state=random state)
# Create a simple classifier
classifier = svm.LinearSVC(random_state=random_state)
classifier.fit(X train, y train)
y score = classifier.decision function(X test)
```

# PR Python 2 класса


Compute average precision (AP) from prediction scores

AP summarizes a precision-recall curve as the weighted mean of precisions achieved at each threshold, with the increase in recall from the previous threshold used as the weight:

$$AP = \sum_{n} (R_n - R_{n-1}) P_n$$

where  $P_n$  and  $R_n$  are the precision and recall at the nth threshold [1]. This implementation is not interpolated and is different from computing the area under the precision-recall curve with the trapezoidal rule, which uses linear interpolation and can be too optimistic.

Note: this implementation is restricted to the binary classification task or multilabel classification task.



```
from sklearn.metrics import precision recall curve
from sklearn.metrics import average precision score
# For each class
precision = dict()
recall = dict()
average precision = dict()
for i in range(n classes):
    precision[i], recall[i], = precision recall curve(Y test[:, i],
                                                        y_score[:, i])
    average precision[i] = average precision score(Y test[:, i], y score[:, i])
# A "micro-average": quantifying score on all classes jointly
precision["micro"], recall["micro"], _ = precision recall curve(Y_test.ravel(),
    y score.ravel())
average precision["micro"] = average precision score(Y test, y score,
                                                     average="micro")
print('Average precision score, micro-averaged over all classes: {0:0.2f}'
      .format(average precision["micro"]))
```

## 3 класса PR Python

#### numpy.ravel

```
numpy.ravel(a, order='C')

Return a contiguous flattened array.
```

После бинаризации получаем только два класса: 0 и 1

```
>>> x = np.array([[1, 2, 3], [4, 5, 6]])
>>> np.ravel(x)
array([1, 2, 3, 4, 5, 6])
>>> x.reshape(-1)
```

It is equivalent to reshape (-1, order=order).


```
array([1, 2, 3, 4, 5, 6])

>>> np.ravel(x, order='F')
array([1, 4, 2, 5, 3, 6])
```

```
plt.figure()
plt.step(recall['micro'], precision['micro'], where='post')

plt.xlabel('Recall')
plt.ylabel('Precision')
plt.ylim([0.0, 1.05])
plt.xlim([0.0, 1.0])
plt.xlim([0.0, 1.0])
plt.title(
    'Average precision score, micro-averaged over all classes: AP={0:0.2f}'
    .format(average_precision["micro"]))
```


#### Average precision score, micro-averaged over all classes: AP=0.43



```
# Import some data to play with
iris = datasets.load iris()
X = iris.data
y = iris.target
# Binarize the output
y = label binarize(y, classes=[0, 1, 2])
n classes = y.shape[1]
# Add noisy features to make the problem harder
random state = np.random.RandomState(0)
n_samples, n_features = X.shape
X = np.c [X, random state.randn(n samples, 200 * n features)]
# shuffle and split training and test sets
X train, X test, y train, y test = train test split(X, y, test size=.5,
                                                    random state=0)
# Learn to predict each class against the other
classifier = OneVsRestClassifier(svm.SVC(kernel='linear', probability=True,
                                 random state=random state))
y score = classifier.fit(X train, y train).decision function(X test)
# Compute ROC curve and ROC area for each class
fpr = dict()
tpr = dict()
roc auc = dict()
for i in range(n classes):
    fpr[i], tpr[i], _ = roc curve(y_test[:, i], y_score[:, i])
    roc_auc[i] = auc(fpr[i], tpr[i])
# Compute micro-average ROC curve and ROC area
fpr["micro"], tpr["micro"], = roc curve(y test.ravel(), y score.ravel())
roc auc["micro"] = auc(fpr["micro"], tpr["micro"])
```


# ROC Python 2 класса

Plot of a ROC curve for a specific class



```
# First aggregate all false positive rates
all fpr = np.unique(np.concatenate([fpr[i] for i in range(n classes)]))
# Then interpolate all ROC curves at this points
mean tpr = np.zeros like(all fpr)
for i in range(n classes):
    mean_tpr += interp(all fpr, fpr[i], tpr[i])
# Finally average it and compute AUC
mean tpr /= n classes
fpr["macro"] = all fpr
tpr["macro"] = mean tpr
roc auc["macro"] = auc(fpr["macro"], tpr["macro"])
# Plot all ROC curves
plt.figure()
plt.plot(fpr["micro"], tpr["micro"],
         label='micro-average ROC curve (area = {0:0.2f})'
               ''.format(roc auc["micro"]),
         color='deeppink', linestyle=':', linewidth=4)
plt.plot(fpr["macro"], tpr["macro"],
         label='macro-average ROC curve (area = \{0:0.2f\})'
               ''.format(roc auc["macro"]),
         color='navy', linestyle=':', linewidth=4)
colors = cycle(['aqua', 'darkorange', 'cornflowerblue'])
for i, color in zip(range(n classes), colors):
    plt.plot(fpr[i], tpr[i], color=color, lw=lw,
             label='ROC curve of class \{0\} (area = \{1:0.2f\})'
             ''.format(i, roc auc[i]))
plt.plot([0, 1], [0, 1], 'k--', lw=lw)
plt.xlim([0.0, 1.0])
plt.ylim([0.0, 1.05])
plt.xlabel('False Positive Rate')
plt.ylabel('True Positive Rate')
plt.title('Some extension of Receiver operating characteristic to multi-class')
plt.legend(loc="lower right")
plt.show()
```

# ROC Python 3 класса



#### Ссылки

- https://scikitlearn.org/stable/auto examples/model selection/plot roc.html
- <a href="https://stackoverflow.com/questions/56090541/how-to-plot-precision-and-recall-of-multiclass-classifier">https://stackoverflow.com/questions/56090541/how-to-plot-precision-and-recall-of-multiclass-classifier</a>
- https://scikitlearn.org/stable/modules/generated/sklearn.metrics.average\_precision\_sc ore.html#sklearn.metrics.average\_precision\_score
- https://scikitlearn.org/stable/modules/generated/sklearn.preprocessing.label\_binarize. html#sklearn.preprocessing.label\_binarize
- https://scikitlearn.org/stable/auto\_examples/model\_selection/plot\_roc.html#areaunder-roc-for-the-multiclass-problem

#### Sklearn examples

PR: <a href="http://scikit-learn.org/stable/auto\_examples/model\_selection/plot\_precision\_recall\_html">http://scikit-learn.org/stable/auto\_examples/model\_selection/plot\_precision\_recall\_html</a>

ROC: <a href="http://scikit-">http://scikit-</a>

learn.org/stable/auto examples/model selection/plot roc.html

Fscore: <a href="http://scikit-">http://scikit-</a>

<u>learn.org/stable/modules/generated/sklearn.metrics.precision\_recall\_f</u>

score\_support.html

#### Ссылки

#### Метрики оценки качества для различных задач:

http://scikit-learn.org/stable/modules/model\_evaluation.html

#### Метрики оценки качества Kaggle:

https://www.kaggle.com/wiki/Metrics